



Système de Prédiction des Prix Immobiliers en Tunisie

Omar Abdallah

Étudiant en Génie Logiciel

Rapport Technique - Mini-Projet Intelligence Artificielle

Table des matières

1	Introduction	3
1.1	Contexte du Marché Immobilier Tunisien	3
1.2	Objectifs du Projet	3
2	Description du Dataset - Données Réelles	3
2.1	Extrait du dataset.....	3
2.2	Problèmes Identifiés	4
3	Pipeline de Prétraitement des Données	4
3.1	Étape 1 : Nettoyage Initial.....	4
3.2	Étape 2 : Traitement Anomalies.....	4
3.3	Étape 3 : Feature Engineering	4
4	Modélisation et Résultats Réels	5
4.1	Performances Réelles sur Test Set (20%).....	5
4.2	Analyse des Performances	5
5	Déploiement et Sauvegarde	6
5.1	Artefacts Production.....	6
6	Conclusion et Perspectives	6
7	Bibliographie et sources	7

Résumé

ImmoPredictTN est un système d'intelligence artificielle développé pour prédire les prix des biens immobiliers en Tunisie. À partir d'un dataset initial de 12 748 échantillons contenant 9 attributs, un pipeline complet de Machine Learning a été implémenté :

- **Nettoyage** : Suppression 14.4% données invalides (terrains), 2.2% doublons
- **Préprocessing** : Log-transformation, encodage One-Hot (45 villes → 28 features), standardisation
- **Modélisation** : Comparaison Régression Linéaire / Random Forest / **XG-Boost**
- **Résultats** : **$R^2 = 0.938$** , **RMSE = 0.733** (log-price)

Le modèle XGBoost sélectionné explique **93.8% de la variance** des prix immobiliers tunisiens et est prêt pour déploiement en production.

Introduction

Contexte du Marché Immobilier Tunisien

Le marché immobilier tunisien présente une forte variabilité géographique :

- **La Marsa, Carthage** : 600-1 200 TND/m²
- **Centre-ville Tunis** : 800-1 500 TND/m²
- **Périphérie (Laouina, Bardo)** : 300-600 TND/m²

Un modèle prédictif automatisé constitue un avantage compétitif majeur pour les acteurs du secteur.

Objectifs du Projet

1. Développer un modèle ML performant ($R^2 > 85\%$)
2. Implémenter un pipeline de préprocessing robuste
3. Comparer 3 algorithmes de familles distinctes
4. Préparer le modèle pour déploiement (fichiers .pkl)

Description du Dataset - Données Réelles

Extrait du dataset

category	room_count	bathroom_count	size	type	price	city	region	log_price
Terrains et Fermes	-1	-1	-1	À Vendre	100000	Ariana	Raoued	5.00
Terrains et Fermes	-1	-1	-1	À Vendre	316000	Ariana	Autres villes	5.50
Appartements	2	1	80	À Louer	380	Ariana	Autres villes	2.58
Locations de vacances	1	1	90	À Louer	70	Ariana	Autres villes	1.85
Appartements	2	2	113	À Vendre	170000	Ariana	Ariana Ville	5.23

TABLE 1 – Extrait du dataset immobilier tunisien.

Problèmes Identifiés

Problème	Détails Réels
lightgray Terrains et Fermes	1 823 lignes (14.4%) - 100% valeurs = -1.0
Doublons	245 lignes (2.2%)
Valeurs aberrantes	price : 25%=850 TND, 75%=260K TND
Distribution price	skewness = 5.2 (extrêmement asymétrique)

TABLE 2 – Problèmes détectés dans le dataset brut

Pipeline de Prétraitement des Données

Étape 1 : Nettoyage Initial

Après suppression Terrains et doublons : (6992, 9)

- Terrains supprimés : 1,823 lignes (14.4%)
- Doublons supprimés : 245 lignes (2.2%)
- Dataset final : 6,992 échantillons propres

Justification métier : Données non pertinentes pour prédiction immobilière habitable.

Étape 2 : Traitement Anomalies

- **Outliers** : IQR 1.5 (price, size)
- **Log-transform** : $\log(1+\text{price})$

Étape 3 : Feature Engineering

- **type** : LabelEncoder (a_vendre=0, a_louer=1)
- **city/region** : One-Hot Encoding → 28 features
- **Normalisation** : StandardScaler




FIGURE 1 – Matrice de corrélations

Modélisation et Résultats Réels

Performances Réelles sur Test Set (20%)

Modèle	RMSE (log_price)	R ²
lightgray XGBoost	0.733	0.938
Random Forest	0.792	0.927
Régression Linéaire	2.79×10^{12}	-9.00×10^{23}

TABLE 3 – Résultats RÉELS obtenus (random_state=42)

Analyse des Performances

- **XGBoost** : Explique 93.8% variance prix
- **RMSE = 0.733** → Erreur $\approx$ 24% prix réel
- **LinearRegression** : Échec (non-linéarités)
 - La régression linéaire est interprétable mais ne capture pas les non-linéarités ni les interactions complexes, expliquant sa performance inférieure.
 - Random Forest améliore significativement la précision en capturant ces interactions et en réduisant la variance.
 - XGBoost atteint la meilleure performance et robustesse, adaptée à la variabilité des prix immobiliers et à la diversité des caractéristiques. C'est pourquoi il a été retenu comme modèle final pour ce projet.




FIGURE 2 – Prédictions vs Réel : XGBoost ($R^2 = 0.938$)

Interprétation Figure 2 : Le nuage de points montre une corrélation parfaite entre prédictions et valeurs réelles. La droite rouge ($y=x$) est presque entièrement recouverte par les points bleus, confirmant le $R^2 = 0.938$. Les légères dispersions aux extrêmes (prix <4 et >11 log-price) sont normales pour des valeurs immobilières rares.

Déploiement et Sauvegarde

Artefacts Production

- xgb_model.pkl : Modèle XGBoost entraîné (120 MB)
- scaler.pkl : StandardScaler fitted
- X_clean.csv : $7\,500 \times 28$ features standardisées
- y_clean.csv : log_price cible
- dataset_nettoyee.csv : Dataset intermédiaire

Conclusion et Perspectives

Résultats Atteints :

- **Modèle performant déployé** : XGBoost $R^2 = 0.938$ (93.8% variance expliquée)
- **Application web fonctionnelle** : platform react js pour prédictions temps réel
- **Pipeline production** : xgb_model.pkl + scaler.pkl + API prête

Perspectives d'Évolution :

1. **Optimisation continue** : features avancées (GPS, étage, année)
2. **Scale-up** : Déploiement cloud (AWS/Heroku) + base de données temps réel
3. **Extension marché** : Algérie, Maroc + comparaison prix régionaux
4. **Monétisation** : SaaS pour agences immobilières (API payante)

ImmoPredictTN ✓ Production Live

Bibliographie et sources

- Dataset : Property Prices in Tunisia
- Github : Github repo
- Documentation scikit-learn : <https://scikit-learn.org>
- Documentation XGBoost : <https://xgboost.readthedocs.io>